

项目一：MSA

人工智能 CS410 2021年秋季

姓名：李子龙 学号：518070910095 日期：2021 年 10 月 14 日

目录

1	题目	2
1.1	Topic	2
1.2	Requirements	2
1.3	Rules	2
2	动态规划算法	2
2.1	双序列比对	2
2.2	多序列比对	3
2.3	运行时间	5
3	A* 算法	5

1 题目

1.1 Topic

Implement three algorithms to solve multiple sequence alignment (MSA) problems.

1.2 Requirements

- (1) Implement dynamic programming (DP) algorithm to find the optimal solution.
- (2) Implement A-star (A*) algorithm to find the optimal solution.
- (3) Implement genetic algorithm to find the optimal/suboptimal solution.

1.3 Rules

表 1: Cost Matrix			
	Match $\alpha(p, p)$	Mismatch $\alpha(p, q)$	Gap δ
Cost	0	3	2

The table above shows the pairwise cost matrix. For multiple sequence alignment, the cost should be calculated in a cycle pairwise manner. Note that GAP-GAP is a match and should be considered as 0 cost. For every query, find the best alignment(s) in the database with the lowest cost.

2 动态规划算法

2.1 双序列比对

在算法与复杂性课程^[1]里, 已经提到了双序列比对的动态规划算法, 如图 1 所示, 双序列比对对于一个状态只需要考虑三个临近状态的转移, 分别是对齐 α , 间隔 δ_x 、 δ_y , 转换行动如表 2 所示。对于每一个状态, 都需要考虑经过哪一条路径消耗最小, 于是就有了如算法 1 的动态规划状态转移方程。

Algorithm 1: 双序列比对动态规划 MSA

Input: $x_1x_2 \cdots x_m, y_1y_2 \cdots y_n, \alpha, \delta$

Output: 最小损耗

```

1 for  $i \leftarrow 0$  to  $m$  do  $M[i, 0] = i\delta$ ;
2 for  $j \leftarrow 0$  to  $n$  do  $M[0, j] = j\delta$ ;
3 for  $i \leftarrow 1$  to  $m$  do
4   for  $j \leftarrow 1$  to  $n$  do
5      $M[i, j] = \min(\alpha[x_i, y_j] + M[i-1, j-1], \delta + M[i-1, j], \delta + M[i, j-1]);$ 
6 return  $M[m, n]$ ;

```

表 2: 双序列行动坐标变换表

	i	j
α	+1	+1
δ_x	0	+1
δ_y	+1	0




图 1: 双序列比对

2.2 多序列比对

对于三序列比对，情况就复杂地多，需要同时考虑七条路径。

表 3: 三序列行动坐标变换表

	k	j	i
$\alpha_x \delta_y \delta_z$	0	0	1
$\delta_x \alpha_y \delta_z$	0	1	0
$\delta_x \alpha_y \alpha_z$	0	1	1
$\delta_x \delta_y \alpha_z$	1	0	0
$\alpha_x \delta_y \alpha_z$	1	0	1
$\alpha_x \alpha_y \delta_z$	1	1	0
$\alpha_x \alpha_y \alpha_z$	1	1	1




图 2: 三序列比对

可以统一化为多序列比对问题。对于 L 条序列比对，首先需要递归地初始化低维度边缘（如图 3 所示），之后余下空间其行动转换方法可以被表示为二进制从 $(\underbrace{0 \cdots 01}_L)_2$ 到 $(\underbrace{1 \cdots 11}_L)_2$ 内所有的数（最低位为第一维度），计算损耗使用上三角成对比较，规则统一为

$$\text{compare} = \begin{cases} 0, & (-, -) \parallel (p, p) \\ 2, & (p, -) \parallel (-, q) \\ 3, & (p, q) \end{cases}$$

并在确定每一次行动后记录路径，最后回溯路径到原点。




图 3: 降维递归

几乎类似于双序列比对，下面是 numpy 实现版本，虽然其速度没有使用 Python 内置的 list 版本 (`msa_mdp.py`) 的快，但是代码可读性已经与伪代码相当。

Listing 1: `msa_mdp.py`

```

44 def editDistanceDP(S,dist:np.array=np.array([]),move:np.array=np.array([])):
45     L = len(S)
46     if L == 1:
47         dist = np.array([i*delta for i in range(len(S[0])+1)])
48         move = np.ones(shape=(len(S[0])+1), dtype=np.uint8)
49         move[0] = 0 # origin is 0
50         return dist, move
51     if len(dist)==0:
52         # initialize dist and move
53         shape = tuple(len(S[l])+1 for l in range(L))
54         dist = np.ones(shape=shape, dtype=np.int32)
55         dist = -1 * dist # negative means no data
56         move = np.zeros(shape=shape, dtype=np.uint8)
57         # calculate the lower dimension (edges)
58         for s in range(L):
59             slicer = tuple(0 if i==s else slice(None) for i in range(L)) # slice(
None) stands for : symbol
60             dist[slicer], move[slicer] = editDistanceDP(S[0:s]+S[s+1:L], dist[slicer
], move[slicer]) # skip S[s]
61             # configure move, insert 0 in the corresponding bit
62             # Example: 4-dim xyzw xyw cube z(2) = 0, get an move 111(wyx), but with
that be zero, it should be 1011.
63             # REMEMBER to place the right end in the same level!
64             move[slicer] = (move[slicer] >> s << (s+1)) + (move[slicer] & (2**s-1))
65             # Spread the remaining space, since the edge case has been considered, the
remaining space will have the same action set.
66             it = np.nditer(dist, flags=['multi_index'], op_flags=["readwrite"])
67             while not it.finished:
68                 pos = it.multi_index
69                 if 0 in pos:
70                     it.iternext()
71                     continue # calculated
72                 ## The range of available move is 1~(2^L-1)
73                 minmove = np.uint8(0)
74                 minvalue = np.inf
75                 for m in range(1,2**L):
76                     move_vec = decodeMove(m,L)
77                     prev_pos = tuple(a-b for a,b in zip(pos,move_vec))
78                     penalty = comparelist([S[a][p] if move_vec[a]==1 else "-" for a,p in
enumerate(prev_pos)])
79                     moved_dist = dist[prev_pos] + penalty
80                     if moved_dist < minvalue:
81                         minmove = m
82                         minvalue = moved_dist
83                 it[0] = minvalue
84                 move[pos] = minmove
85                 it.iternext()
86             return dist, move

```

2.3 运行时间

如果字符串平均长度为 l ，该算法 L 维字符串的复杂度为：

$$O_S = \prod_{i=1}^L \text{len}(S[i]) \approx l^L$$

对于该问题，有 m 个待比对序列， n 个数据库项目，总时间复杂度为：

$$mC_n^{L-1}O_S \approx mC_n^{L-1}l^L$$

实际运行时间如表 4，在服务器上运行时间如下。

表 4: 动态规划运行时间

	双序列		三序列	
	朴素实现 <code>msa_dp.py</code>	list实现 <code>msa_mdp.py</code>	list实现 <code>msa_mdp.py</code>	numpy实现 <code>msa_ndp.py</code>
运行时间	29s	1min	24h	~36h

3 A* 算法

使用启发函数 $g(n) = |\text{len}(S_1) - \text{len}(S_2)|$ 。

参考文献

- [1] XIAOFENG G. Algorithm & complexity class lab 06[EB/OL]. 2021. <https://github.com/LogCreative/AlgAndComplexity/blob/master/Lab06/Code-SequenceAlignment.cpp>.